

Modulabschlussprüfung

Modul: Data Science und KI

6. Semester, Montag, 01-06.2026

Zeit: 10:30 – 11:30 Uhr

Prüfungsdauer: 60 Minuten

Nachname, Vorname: _____

Klasse: _____

Erreichte Punktzahl: _____ **(max. Punktzahl: 00)**

Note: _____

Hinweise:

1. Bei Verstößen gegen das Prüfungsreglement erfolgt ein sofortiger Ausschluss von der Prüfung.
Es wird die Note 1.0 erteilt.
2. Blätter ohne Namens- und Klassenangaben werden nicht korrigiert.
3. Erlaubt sind: Kugelschreiber blau oder schwarz, Tipp-ex, Leuchtstift
4. Erlaubte Hilfsmittel: Spick/Open Book (nur auf Papier)

Selbstständigkeitserklärung:

Hiermit versichere ich, dass diese Prüfung von mir persönlich und ohne fremde Hilfe während der Prüfungszeit bearbeitet und gelöst wurde.

Mir ist bewusst, dass Zuwiderhandlungen gegen obige Erklärung, die auch nach der Prüfungszeit nachweisbar sind, zur Bewertung der Prüfung mit der Note 1.0 führen.

Ort, Datum

Unterschrift

Modulabschlussprüfung

Modul: Data Science und KI

Aufgabe 1

(6 Punkte)

CSV-Import, Time-Index und Resampling

Eine Datei `raumluft.csv` soll zu stündlichen CO2-Mittelwerten verarbeitet werden. Ein Student schreibt:

```
df = pd.read_csv("raumluft.csv")
df = df.set_index("timestamp")
df_1h = df.resample("1h").mean()
```

Beim Einlesen landet jede Zeile in einer einzigen Spalte, und das Resampling würde auch sonst nicht wirklich funktionieren.

a) Nenne eine sinnvolle Korrektur beim Einlesen.

b) Nenne eine sinnvolle Korrektur vor dem Resampling im Umgang mit `timestamp`.

c) Erkläre in Worten, was `df_1h["co2"]` nachher enthält.

d) Nenne ein Beispiel, bei dem `max()` sinnvoller wäre als `mean()`.

Aufgabe 2

(5 Punkte)

Join und Interpolation

Zwei zeitindizierte Dataframes `co2_df` und `temperature_df` werden zusammengeführt. Einige Zeitpunkte kommen nur in einer der beiden Dataframes vor. Nach dem Join gibt es zusätzlich Lücken in `co2`, `temperature` und im binären Bewegungssensor `pir` (0/1).

a) Erkläre den Unterschied zwischen `inner` und `outer` Join in dieser Situation.

b) Welchen Join würdest du wählen, wenn alle Zeitpunkte aus beiden Quellen erhalten bleiben sollen? Begründe kurz.

c) Für welche der drei Spalten ist lineare Interpolation eher sinnvoll, und für welche eher fragwürdig? Begründe kurz.

Aufgabe 3

(4 Punkte)

Deskriptive Statistik und Plotwahl

Gegeben ist die folgende Zusammenfassung:

- Raum A: mean temperature = 23.8, std = 0.7
- Raum B: mean temperature = 22.9, std = 2.4

a) Welcher Raum ist im Mittel wärmer?

b) Welcher Raum schwankt stärker?

c) Welchen Plot würdest du wählen, um den Temperaturverlauf über die Zeit zu zeigen?

d) Welchen der im Unterricht behandelten Plottypen würdest du wählen, um Verteilung und mögliche Ausreisser zu prüfen?


Aufgabe 4

(5 Punkte)

Korrelation und Modellwahl

Die Punktwolke in Abbildung 1 steigt klar an, ist aber nicht annähernd gerade. Für dieselben Daten gelten:

- Pearson = 0.78
- Spearman = 0.88



a) Welcher Koeffizient passt besser zur Punktwolke, und warum?

b) Was sagt das über den Zusammenhang zwischen den Variablen aus?


c) Wäre eine einfache lineare Regression hier als Endmodell wahrscheinlich ausreichend? Begründe kurz.

Aufgabe 5

(4 Punkte)

Lineare Regression, Residuen und Fehlermasse

Eine lineare Regression sagt co_2 aus $light$ voraus. Das Modell hat eine positive Steigung. Der Residuenplot ist in Abbildung 2 gezeigt.



a) Was bedeutet die positive Steigung in diesem Kontext?

b) Was deutet dieses Residuenmuster über das KI-Modell an?

c) Warum reagiert der MSE stärker auf grosse Fehler als der MAE?

Aufgabe 6

(6 Punkte)

Train/Test, Overfitting und Modellvergleich

Drei Modelle werden auf demselben Regressionsproblem bewertet:

- Linear Regression: train MSE = 120, test MSE = 135
- Decision Tree: train MSE = 8, test MSE = 260
- KNN: train MSE = 95, test MSE = 110

a) Welches Modell würdest du im Moment wählen? Begründe kurz.

b) Welches Modell zeigt das klarste Zeichen von Overfitting? Begründe kurz.

c) Warum reicht ein sehr kleiner Trainingsfehler allein nicht aus?

d) Warum ist ein separates Testset wichtig?
